Clusterizacao de Clientes &
Regras de Associacao

Data Warehouse Organizacional - Mercearia + Northwind

Data Mart: dm_vendas (PostgreSQL)
Tecnicas: K-Means + Apriori (Ensemble nao-supervisionado)
Linguagem: Python - Pandas, NumPy, Scikit-learn, MLxtend, SQLAlchemy
Resultado: 3.804 Regras de Associacao geradas e persistidas
Data: Outubro / 2026

189	4	930	3.804
Clientes Segmentados	Clusters Identificados	Cestas Analisadas	Regras de Associacao

Pagina 2 - Contexto e Objetivos

O que foi feito e por que

Objetivo do Projeto

Aplicar tecnicas de mineracao de dados sobre o Data Warehouse Organizacional para descobrir padroes de comportamento de compra dos clientes, integrando duas fontes transacionais distintas (Mercearia B2C e Northwind B2B) via Data Mart dm_vendas.

Mercearia - Perfil B2C

Clientes: 100 | Tipo: Consumidor final

Cestas: 100 pedidos com ~10 itens cada

Catalogo: 100 produtos de alta rotatividade

Suporte max. individual: 30% das cestas

Northwind - Perfil B2B

Clientes: 89 | Tipo: Empresas/distribuidores

Cestas: 830 pedidos com 2-3 itens cada

Catalogo: 77 produtos gourmet importados

Suporte max. individual: 7,1% das cestas

Pipeline da Solucao - 4 Etapas

1

Clusterizacao

K-Means segmenta 189 clientes em 4 grupos com 7 variaveis comportamentais

2

Segmentacao

Transacoes de cada cliente sao rotuladas pelo cluster de origem

3

Market Basket

Apriori e executado independentemente dentro de cada cluster

4

Persistencia

3.804 regras gravadas em dm_vendas.regras_associacao (PostgreSQL) + CSV

Diferencial: O Apriori NAO e executado sobre todos os clientes simultaneamente - ele opera dentro de cada segmento identificado pelo K-Means, gerando regras muito mais precisas e acionaveis.

Pagina 3 - Arquitetura da Solucao

Fluxo completo de dados e processamento

Componentes Tecnicos



DW Organizacional

dw_organizacional

Integracao Mercearia e Northwind

Data Mart

dm_vendas

Modelagem estrela: dim_cliente, dim_produto, fato

View Clusterizacao

vw_cliente_clusterizacao

7 variaveis comportamentais por cliente

Tabela Clusters

cliente_cluster

Resultado do K-Means persistido no PostgreSQL

View Compras

vw_compras_por_cluster

id_transacao unificado por pedido + cluster

Tabela Regras

regras_associacao

3.804 regras persistidas para uso em BI/ML

Detalhe Tecnico - id_transacao

Para evitar colisao de IDs entre Mercearia e Northwind (ambos com pedido no 10, por ex.), o id_transacao e construido como: sistema_origem + '_' + id_pedido

Ex.: 'MERCEARIA_51' | 'NORTHWIND_10249'

Isso garante unicidade global em todo o Data Mart.

Granularidade da Cesta vs. Granularidade da Linha

A tabela fato armazena dados na granularidade de item de venda (1 produto por linha).

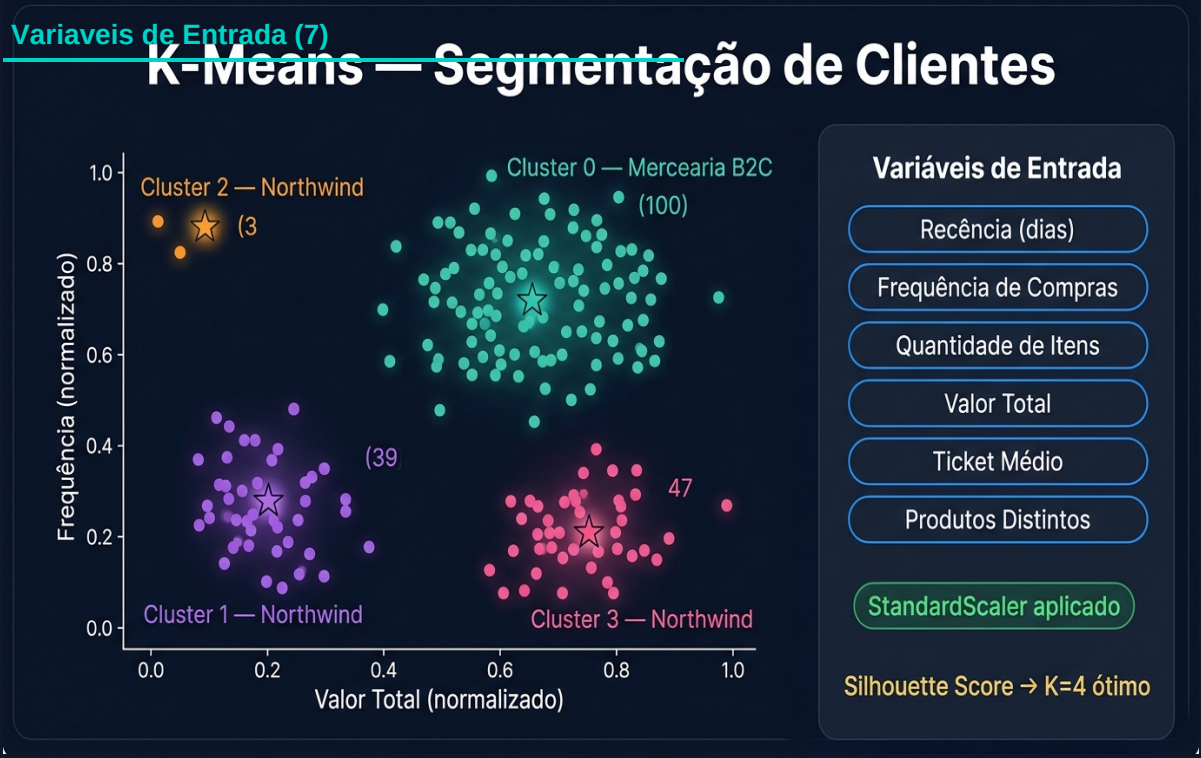
Mercearia: 100 vendas reais agrupando 1.000 itens -> media de 10 produtos por cesta.

Northwind: 830 pedidos reais agrupando 2.155 itens -> media de 2 a 3 produtos por cesta.

Pagina 4 - K-Means: Segmentacao de Clientes

Normalizacao, Algoritmo e Selecao do K otimo

Variaveis de Entrada (7)



recencia_dias	Dias desde a ultima compra
frequencia_compras	No. de transacoes realizadas
quantidade_itens	Total de itens comprados
valor_total	Valor financeiro total (R$)
ticket_medio	= valor_total / frequencia
produtos_distintos	Qtd. de produtos diferentes
categorias_distintas	Qtd. de categorias diferentes

Normalizacao - StandardScaler

Antes do K-Means, todas as variaveis passam pelo StandardScaler (media=0, desvio=1). Sem normalizacao, valor_total (escala de milhares) dominaria o calculo de distancia euclidiana, tornando as demais variaveis irrelevantes para a segmentacao.

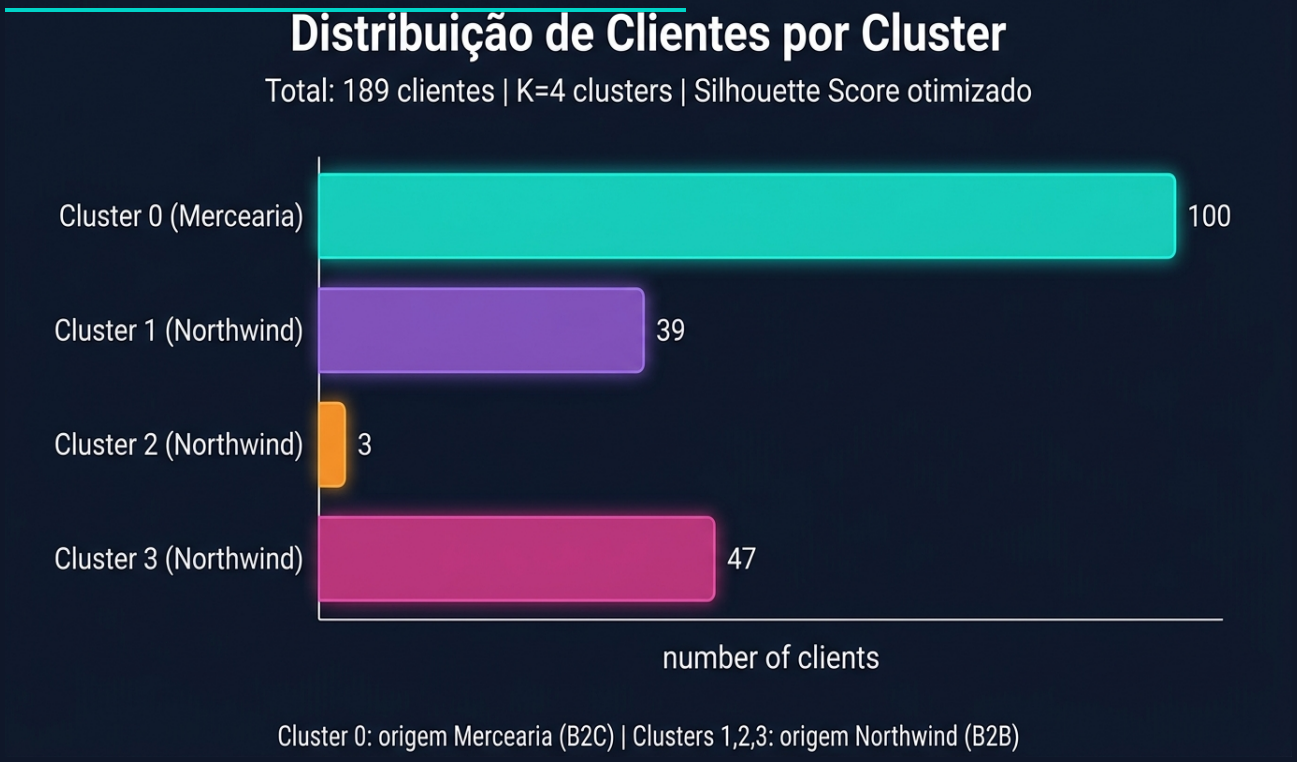
Selecao do K otimo: Testados K=2 a K=7. O Silhouette Score foi calculado para cada K, medindo coesao interna + separacao entre clusters. K=4 maximizou o score.

Silhouette Score: mede quao proximo cada elemento esta dos outros do seu proprio cluster em relacao aos demais clusters. Valores entre -1 e +1; maior = melhor.

Pagina 5 - Distribuicao dos 4 Clusters

189 clientes segmentados em 4 grupos distintos

Resumo por Cluster



Cluster	Origem	Clientes	Cestas	Produtos
0	Mercearia B2C	100	100	100
1	Northwind B2B	39	478	77
2	Northwind B2B	3	89	74
3	Northwind B2B	47	263	76
Total	-	189	930	-

Interpretacao dos Clusters

Cluster 0 (Mercearia B2C):

Cestas compostas com ~10 itens. Catalogo concentrado em 40 produtos de alta rotatividade. Cada produto aparece em 30% das cestas. Alta densidade -> 3.804 regras geradas.

Cluster 1 (Northwind B2B):

39 clientes com 478 pedidos. Catalogo gourmet disperso. Cestas enxutas (2-3 itens). Suporte max. 7,1% - abaixo do limiar para pares de produtos.

Cluster 2 (Northwind B2B):

Apenas 3 clientes - provavel segmento VIP com volume alto. 89 pedidos mas catalogo disperso.

Cluster 3 (Northwind B2B):

47 clientes com 263 pedidos. Perfil intermediario B2B. Catalogo disperso impede regras com suporte >= 5%.

Pagina 6 - Pipeline Apriori: Market Basket Analysis

TransactionEncoder, Suporte, Confianca e Lift

Etapas do Algoritmo Apriori

Transacoes por Cluster
id_transacao unificado por pedido completo

>

Transaction Encoder
Matriz binaria: Produto x Transacao (0/1)

>

Frequent Itemsets
Conjuntos frequentes: suporte >= 5% (min_support=0.05)

>

Association Rules
Regras geradas: conf >= 0.30 | lift >= 1.0

>

3.804 Regras Cluster 0
Persistidas no PostgreSQL + CSV

A Matriz de Transacoes

O TransactionEncoder (MLxtend) converte a lista de cestas em uma matriz binaria onde:

- Linhas = transacoes (pedidos completos)
- Colunas = produtos do catalogo
- Valor 1 = produto presente na transacao | Valor 0 = produto ausente

Cluster 0 (Mercearia): Matriz de 100 transacoes x 40 produtos ativos (suporte >= 5%)

Parametros Utilizados

MIN_SUPPORT
0.05 (5%)
O itemset deve aparecer em >= 5% das transacoes do cluster

MIN_CONFIDENCE
0.30 (30%)
Certeza minima: P(consequente|antecedente) >= 30%

MIN_LIFT
1.00
Apenas associacoes positivas - acima da compra aleatoria

Execucao por Cluster

Cluster 0 -> Apriori(100 cestas x 40 produtos) -> 3.804 regras (OK)
Cluster 1 -> Apriori(478 cestas x 77 produtos) -> 0 regras (suporte < 5%)
Cluster 2 -> Apriori(89 cestas x 74 produtos) -> 0 regras (suporte < 5%)
Cluster 3 -> Apriori(263 cestas x 76 produtos) -> 0 regras (suporte < 5%)

NOTA: Reduzindo para MIN_SUPPORT = 1%-2%, surgem regras validas nos clusters Northwind.

Pagina 7 - Metricas das Regras de Associacao

Suporte, Confianca e Lift

Definicao das Metricas



SUPORTE — 0.16 (16%)

Frequencia do itemset nas transacoes.
support(A,B) = transacoes com A e B / total de transacoes
Garante que a regra nao e baseada em ocorrencias raras.

CONFIANCA — 1.00 (100%)

Probabilidade condicional do consequente dado o antecedente.
confidence(A->B) = support(A,B) / support(A)
Mede a forca da implicacao da regra.

LIFT — 5.00x

Razao entre confianca observada e esperada (se independentes).
lift(A->B) = confidence(A->B) / support(B)
Lift > 1 = associacao positiva genuina (nao aleatoria).

Interpretacao do Lift = 5,00

Se Agua Mineral fosse comprada aleatoriamente em 20% das cestas (support = 0.20), ao encontra-la junto com {Achocolatado 400g, Agua Sanitaria 1L}, ela aparece em 100% das cestas - exatamente 5x mais do que o esperado ao acaso.

Interpretação do Lift

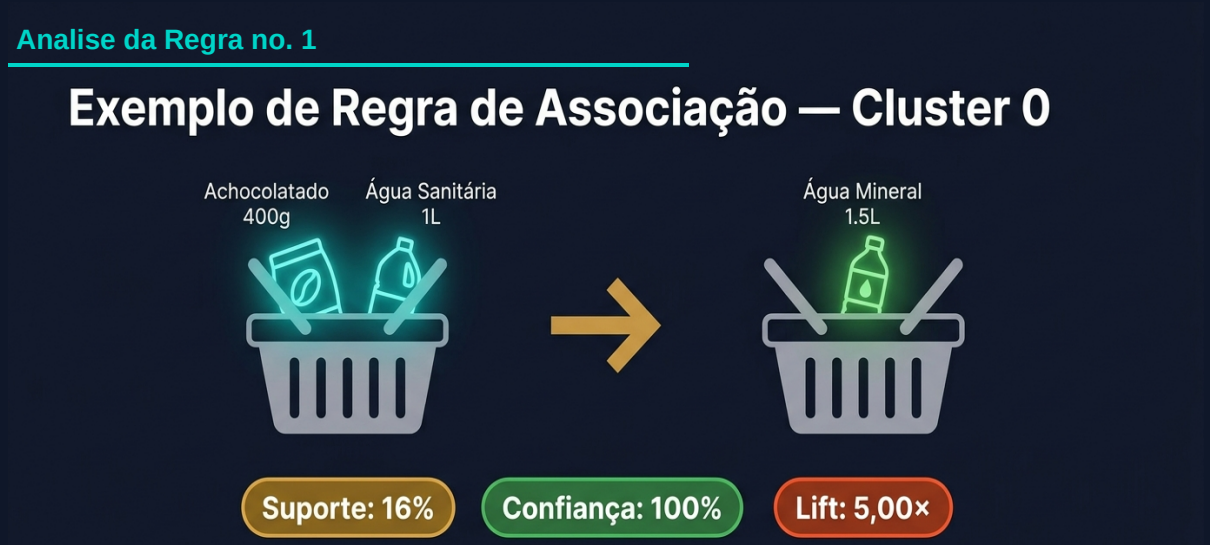
Isso indica uma associação positiva: o consequente ocorre mais frequentemente na presença do antecedente do que seria esperado sob independência.

Faixa de Lift	Interpretacao	Acao Recomendada
Lift < 1	Associacao negativa	Evitar promocoes cruzadas entre eles
Lift = 1	Independencia - sem padrao	Ignorar - sem valor preditivo
1 < Lift < 3	Associacao fraca-moderada	Considerar para recomendacoes sec.
3 <= Lift < 5	Associacao forte	Usar em promocoes e layout de gondola

Pagina 8 - Exemplo Concreto de Regra de Associacao

Cluster 0 - Mercearia B2C

Analise da Regra no. 1



Regra de Associacao #1 - Cluster 0

ANTECEDENTES:

Achocolatado 400g - Marca A

Agua Sanitaria 1L - Marca E

CONSEQUENTE:

Agua Mineral 1.5L - Marca C

16%	100%	5,00
Suporte	Confianca	Lift

Interpretacao Pratica

- Suporte (16%):

Interpretação prática

Suporte (16%): os três produtos aparecem juntos em 16 de cada 100 cestas do Cluster 0.
Confiança (100%): todas as cestas com Achocolatado + Água Sanitária também incluem Água Mineral.
Lift (5,00): a associação é cinco vezes mais frequente do que seria esperado ao acaso.

#	Antecedentes	Consequente	Suporte	Confianca	Lift
1	Achocolatado 400g + Agua Sanitaria 1L	Agua Mineral 1.5L	16%	100%	5,0
2	Acucar 1kg + Desinfetante 1L	Creme Dental 90g	16%	100%	5,0
3	Agua Mineral 1.5L + Escova Dental	Agua Sanitaria 1L	16%	100%	5,0
4	Agua Sanitaria 1L + Cafe 500g	Escova Dental	16%	100%	5,0
5	Amaciante 2L + Feijao Carioca 1kg	Condicionador 350ml	16%	100%	5,0
6	Condicionador 350ml + Iogurte Natural	Amaciante 2L	16%	100%	5,0
7	Amaciante 2L + Sardinha 125g	Iogurte Natural	16%	100%	5,0
8	Arroz 5kg + Sabao em Po 1kg	Shampoo 350ml	16%	100%	5,0
9	Atum 170g + Desinfetante 1L	Refrigerante 2L	16%	100%	5,0
10	Cerveja 350ml + Esponja 3un	Papel Toalha 2un	16%	100%	5,0

Pagina 9 - Analise Comparativa dos Clusters

B2C vs. B2B - Por que apenas o Cluster 0 gerou regras?

Diferencas Estruturais B2C vs B2B



Caracteristica	Cluster 0 (Me
Itens por cesta (media)	10 itens
Produtos no catalogo	100 (Cl.0)
Prod. com suporte >= 5%	40
Suporte individual max.	30%
Regras com suporte 5%	3.804 OK
Regras com suporte 1-2%	-

Por que os clusters Northwind nao geraram regras?

Raciocinio matematico para o Cluster 1 (39 clientes, 478 cestas):

Produto mais frequente: Gorgonzola Telino -> 34 ocorrencias = 7,1% de 478 cestas.
Para dois produtos aparecerem JUNTOS em >= 5% das cestas (24 ocorrencias),
eles precisariam estar presentes na mesma cesta 24 vezes.

Aplicações de negócio por cluster

Cluster 0 (B2C): promoções cruzadas, layout de gôndola, kits e recomendação no checkout.
Cluster 1 (B2B): reduzir o suporte para identificar padrões gourmet entre distribuidores.
Cluster 2 (B2B): avaliar o segmento VIP com suporte ainda menor (0,5%?1%).
Cluster 3 (B2B): recomendações personalizadas com suporte de 1%?2%.

Pagina 10 - Conclusoes e Aplicacoes de Negocio

Resultados finais, licoes aprendidas e proximos passos

189	4	930	3.804
Clientes Segmentados	Clusters Identificados	Cestas Analisadas	Regras de Associacao

Aplicacoes Praticas das Regras Descobertas

Promocoes Cruzadas	Desconto em Achocolatado 400g incentiva compra de Agua Mineral. Confianca 100%.
Layout de Gondola	Posicionamento estrategico: produtos com Lift >= 5 devem estar proximos na loja.
Recomendacao no Checkout	Sugestao automatica baseada no cluster do cliente - integracao com BI/sistemas de venda.
Kits Promocionais	Agrupamento de trios com Lift=5,0 em kits: maior ticket medio e satisfacao do cliente.
Analise B2B (Northwind)	Reduzir MIN_SUPPORT para 1-2% e rodar novamente para os clusters 1, 2 e 3.

Licoes Aprendidas

- Granularidade da Fato vs. Cesta

A tabela fato opera no nivel de item de venda (1 linha/produto). Usar id_fato como transacao resultaria em cestas de tamanho 1, impossibilitando o Apriori. Solucao: reconstruir id_transacao no nivel do pedido completo (id_venda / id_order).

- Heterogeneidade de Fontes

Sistemas B2C e B2B exigem MIN_SUPPORT diferentes. Nao existe configuracao unica. A clusterizacao previa com K-Means permite calibrar os parametros por segmento.

- Lift como Filtro de Qualidade

Alta confianca sem Lift > 1 pode indicar regra espuria onde o consequente e um produto muito popular. O Lift garantiu que apenas associacoes genuinas fossem mantidas.