

INSTITUTO FEDERAL
DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA
Goiás

Ensamble: clusterização de clientes com Regras de Associação

Flávio Lourenço da Silva
Gustavo Adolpho Souteras Barbosa

Prof. Dr. Sirlon Diniz

8 de outubro de 2026

Resumo

O presente documento descreve os procedimentos adotados para implementar a clusterização de clientes com regras de associação. Esta combinação é uma estratégia extremamente poderosa para análises de CRM e marketing, onde se aplica regras de associação em toda a base de transações, primeiramente segmentando clientes e depois descobrindo padrões específicos de compra.

1 Introdução

No contexto de relacionamento com clientes (CRM) e marketing, a análise de dados de consumo permite identificar diferentes perfis de consumo e compreender seus padrões, permitindo estratégias mais eficazes.

É neste contexto que a clusterização se torna uma ferramenta muito importante para a identificação de grupos de consumidores e seus comportamentos. Usando aprendizagem não supervisionada, é possível analisar diferentes atributos de clientes e organizá-los em grupos. Essa segmentação pode auxiliar na compreensão das características de consumo e na definição de estratégias específicas para cada grupo.

Outra ferramenta muito importante para esta tarefa é a descoberta de regras de associação, onde se identifica relações e padrões de ocorrência conjunta entre os itens de um conjunto de transações. No contexto de vendas, estas regras podem revelar produtos que tendem a ser adquiridos em conjunto, possibilitando a identificação de padrões de compra que podem ser utilizados em estratégias de recomendação de produtos, vendas cruzadas e planejamento de marketing.

O presente trabalho tem como objetivo aplicar estes conceitos sobre os dados provenientes do Data Warehouse (DW) Organizacional e dos Data Marts previamente desenvolvidos,

2 Projeto

O projeto foi estruturado para seguir a sequência indicada na **Figura 1**.



Figura 1: Pipeline do projeto.
Fonte: os próprios autores

Da forma que foi estruturado, o projeto emprega o Data Warehose Organizacional já criado, através do Data Mart de vendas (*dm_vendas*), para obter informações sobre os clientes. Deste Data Mart, obtèm-se os seguintes atributos da **Dimensão de clientes**:

- `id_cliente_dw`
- `id_pessoa`
- `origem_principal`
- `nome`
- `empresa`
- `cidade`
- `regiao`
- `estado`
- `pais`
- `tipo_cliente`

Da **Dimensão de produtos** emprega-se:

- `id_produto_dw`
- `id_produto`
- `origem_principal`
- `produto`
- `categoria`

Por fim, da tabela **Fato de vendas** emprega-se:

- `id_fato_venda_dw`
- `id_tempo`
- `id_cliente_dw`
- `id_produto_dw`
- `quantidade`
- `valor_unitario`
- `valor_bruto`
- `valor_desconto`
- `valor_liquido`
- `frete`
- `id_origem_registro`
- `sistema_origem`

A granularidade da fato de vendas é de item de venda/pedido. Portanto, uma transação pode possuir várias linhas de produtos. Essa característica é especialmente importante para a etapa de Regras de Associação, pois o algoritmo precisa reconstruir cada compra como uma cesta contendo os produtos adquiridos conjuntamente.

A partir destes atributos consolidou-se algumas variáveis para a clusterização. Estas variáveis são:

Tabela 1: Variáveis comportamentais utilizadas na análise

Variável	**Descrição**
`recencia_dias`	Quantidade de dias desde a última compra
`frequencia_compras`	Quantidade de transações realizadas
`quantidade_itens`	Quantidade total de itens comprados
`valor_total`	Valor total comprado
`ticket_medio`	Valor médio por transação
`produtos_distintos`	Quantidade de produtos diferentes comprados
`categorias_distintas`	Quantidade de categorias diferentes compradas

O algoritmo selecionado para realizar a clusterização foi o *K-Means*. A escolha considerou principalmente o tempo disponível para o desenvolvimento do trabalho, uma vez que o grupo precisava revisar e consolidar os conceitos relacionados aos diferentes métodos de clusterização. Nesse contexto, o K-Means apresentou uma implementação mais simples e direta, permitindo sua aplicação e análise dos resultados dentro do prazo estabelecido. Embora outras abordagens, como as *redes SOM*, apresentem características que poderiam ser interessantes para a análise dos clientes, optou-se pelo *K-Means* como uma solução adequada às restrições de tempo e aos objetivos definidos para o trabalho.

3 Procedimentos

Para preparar os dados para a clusterização, criou-se a visão *dm_vendas.vw_cliente_clusterizacao*, que consolida o comportamento histórico dos clientes. As variáveis trabalhadas nesta visão são apresentadas na **Tabela 1**.

Antes da aplicação do *K-Means*, estas variáveis são padronizadas utilizando o *StandardScaler* do *Scikit-learn*, para colocá-las em uma escala comparável. Sem esta padronização variáveis de grande magnitude poderiam exercer influência excessiva sobre a distância utilizada pelo *K-Means*.

Obtendo-se as variáveis normalizadas, passa-se para a fase de clusterização. Para isto deve-se definir o número de clusters. Isto foi feito testando valores de **K** entre 2 e 7 e avaliando o resultado com o algoritmo **Silhouette Score**. Este algoritmo é uma métrica usada para avaliar a qualidade de uma clusterização e é calculado por:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Onde:

- $a(i)$ representa a distância média do ponto i em relação aos demais pontos do seu próprio cluster;
- $b(i)$ representa a menor distância média do ponto i em relação aos pontos de outro cluster.

Isto é calculado para cada elemento e o resultado varia entre -1 e 1. Se o resultado estiver próximo de 1, os clusters estão muito bem separados. Se estiver próximo de 0 há clusters sobrepostos ou pouco definidos. Já resultados negativos mostra que há elementos mais próximos de outro cluster do que de seu próprio. O código portanto seleciona o valor de **K** que apresenta o maior *Silhouette Score* entre os valores avaliados.

Depois da execução do K-Means, os clusters calculados em Python são armazenados no PostgreSQL, na tabela *dm_vendas.cliente_cluster*. Esta tabela estabelece e faz persistir a relação entre o Cliente e seu Cluster.

Obtendo os clientes separados por grupos, pode-se seguir para a etapa de obter informação sobre o perfil de compras de cada grupo. Para isto, criou-se a visão *dm_vendas.vw_compras_por_cluster*. Ela vai apresentar a seguinte estrutura:

- `cluster`
- `id_cliente_dw`
- `id_transacao`
- `id_produto_dw`
- `produto`
- `categoria`
- `quantidade`
- `valor_liquido`

Cada registro representa um produto pertencente a uma determinada transação de um cliente que foi associado a um cluster. O campo *id_ transacao* é fundamental para a descoberta da associação entre compras. Ele é empregado no algoritmo *Apriori* para descobrir padrões específicos de cada segmento de cliente.

O Apriori é um algoritmo de mineração de dados utilizado para identificar padrões de associação entre itens de um conjunto de dados. Ele é amplamente aplicado em análises de cestas de compras, buscando descobrir quais produtos tendem a ser adquiridos conjuntamente.

O algoritmo trabalha a partir de dois conceitos principais: suporte e confiança. O suporte indica a frequência com que um conjunto de itens aparece nas transações, enquanto a confiança mede a probabilidade de um item ser adquirido quando outro item já foi comprado.

A partir desses critérios, o Apriori gera regras de associação, geralmente representadas no formato:

$$A \Rightarrow B$$

em que A é o antecedente e B é o consequente. Por exemplo, uma regra como:

$$\{\text{Pão}\} \Rightarrow \{\text{Leite}\}$$

indica que clientes que compram pão apresentam determinada probabilidade de também comprar leite.

O funcionamento do Apriori baseia-se no princípio de que se um conjunto de itens é frequente, todos os seus subconjuntos também devem ser frequentes. Dessa forma, o algoritmo elimina combinações que não atendem ao suporte mínimo, reduzindo o número de candidatos analisados.

Sendo assim, para o emprego deste algoritmo nesta tarefa, construiu-se uma matriz de transações, empregando o *TransactionEncoder* da biblioteca *MLxtend*. Ele converte as cestas em uma matriz binária, como no exemplo da **Tabela 2**:

Tabela 2: Exemplo de matriz de transações para aplicação do algoritmo Apriori

Transação	**Arroz**	**Feijão**	**Café**	**Leite**
Venda 1	1	1	0	0
Venda 2	1	0	1	0
Venda 3	0	1	0	1
Venda 4	0	0	1	1

Onde o valor 1 indica que o produto consta na transação.

Como mencionado, o algoritmo se baseia nos conceitos de suporte e confiança. O **suporte** representa a frequência de ocorrência de um conjunto de produtos dentro das transações. Empregou-se inicialmente `MIN_SUPPORT = 0.05`, ou seja, o conjunto precisa aparecer em pelo menos 5% das transações do respectivo cluster.

Já a **confiança** mede a probabilidade de o consequente aparecer quando o antecedente aparece. Para este parâmetro foi empregado `MIN_CONFIDENCE = 0.30`, ou seja, o produto consequente deve aparecer pelo menos 30% nas transações para ser considerado.

Existe ainda outro parâmetro chamado **Lift**, que permite verificar se a associação observada é mairo do que aquela esperada considerando as frequências individuais dos produtos. Para este trabalho empregou-se `MIN_LIFT = 1.00`, que signfica que valores menores que 1 há uma associação negativa, valores iguais a 1 a associação é ausente de relevância e valores maiores que 1 há uma associação positiva. O número resultante é a quantidade de vezes que a ocorrência conjunta é maior do que seria esperado caso os produtos fossem independentes.

Após a identificação dos conjuntos frequentes, o algoritmo *association_rules* gera as regras. Cada regra possui, entre outras, as informações:

- `antecedents`
- `consequents`
- `support`
- `confidence`
- `lift`

Para facilitar a interpretação, os conjuntos de produtos são convertidos para texto. As regras são então ordenadas priorizando maior *Lift*, maior *Confiança* e maior *Suporte*. As primeiras regras então tendem a ser aquelas com maior força de associação. Ao final deste processamento, as regras encontradas em todos os clusters são consolidadas em um único DataFrame do pandas. A estrutura deste contém:

Tabela 3: Estrutura final dos resultados

Campo	**Descrição**
`cluster`	Grupo de clientes
`quantidade_clientes`	Número de clientes no cluster
`quantidade_transacoes`	Número de transações do cluster
`antecedentes`	Produtos que formam o antecedente
`consequentes`	Produto(s) consequente(s)
`support`	Suporte da regra
`confidence`	Confiança da regra
`lift`	Força da associação

Por fim, esta tabela é salva em um arquivo no formato CSV que posteriormente pode ser utilizado para vários tipos de análises.

3.1 Conclusões

Em um trabalho anterior, o grupo pôde perceber a importância de um Data Warehouse como fonte estruturada de informações para um negócio. Restava, entretanto, uma questão: de que forma esses dados poderiam ser empregados de maneira eficiente para gerar conhecimento e apoiar a tomada de decisões?

Ao longo deste projeto, foi possível perceber que conceitos como segmentação de clientes, identificação de padrões de consumo e descoberta de regras de associação podem ser aplicados de forma sistemática e fundamentada, indo além da análise baseada apenas em intuição ou experiência. A utilização de técnicas de aprendizado não supervisionado mostrou ao grupo que grandes volumes de dados gerenciais podem ser explorados para identificar padrões e relações que nem sempre são evidentes por meio de uma análise convencional.

Esse foi, possivelmente, um dos principais aprendizados proporcionados pelo projeto. Até então, o grupo possuía uma visão mais limitada sobre as aplicações do aprendizado não supervisionado. A experiência com o K-Means e o estudo das redes SOM permitiram compreender melhor o potencial dessas técnicas para a análise exploratória e segmentação de dados, especialmente em contextos gerenciais, nos quais a identificação de grupos e padrões pode contribuir para uma compreensão mais aprofundada do comportamento dos clientes.

O grupo também teve a oportunidade de aprofundar seus conhecimentos sobre algoritmos de regras de associação, compreendendo conceitos como suporte, confiança e lift e sua utilização na identificação de relações entre produtos. Dessa forma, o projeto contribuiu não apenas para a aplicação prática das técnicas estudadas, mas também para uma compreensão mais ampla de como diferentes métodos de análise de dados podem ser combinados para transformar dados armazenados em informações relevantes para o processo de tomada de decisão.